

МИНОБРНАУКИ РОССИИ

Федеральное государственное бюджетное образовательное учреждение высшего образования

«МИРЭА – Российский технологический университет»

РТУ МИРЭА

Институт информационных технологий (ИИТ) Кафедра прикладной математики (ПМ)

ОТЧЕТ ПО ПРАКТИЧЕСКОЙ РАБОТЕ №5

по дисциплине «Языки программирования для статистической обработки данных»

Студент группы	ИМБО-11-23, Журавлев Ф.А.	(подпись)
Преподаватель	Трушин СМ	
		(подпись)

1) ЦЕЛЬ И ЗАДАЧИ

Цель практической работы:

Освоить методы анализа корреляций и построения линейных регрессионных моделей с использованием Python, R.

Задачи практической работы:

- 1. Рассчитать корреляцию между переменными:
 - Вычисление коэффициентов корреляции Пирсона и Спирмена.
 - Построение и визуализация корреляционной матрицы:
 - Python: pandas, seaborn.
 - R: cor(), ggcorrplot.
- 2. Построить линейную регрессионную модель:
 - Анализ зависимости одной переменной от другой.
 - Интерпретация результатов регрессии (коэффициенты, R²).
 - Python: statsmodels, sklearn.
 - R: lm().
- 3. Сравнить подходы к расчёту корреляций и регрессии в Python, R.
- 4. Выявить преимущества и ограничения каждого инструмента для анализа данных.

2) РЕЗУЛЬТАТЫ ПРАКТИКИ

Шаг 1) Коэффициенты Спирмана и Пирсона.

1.1) Вычисление коэффициентов в Python.

После загрузки исходной таблицы данных в формате .csv, следует сначала рассчитать коэффициент Спирмана и Пирсона, ниже приведен код:

Рисунок 1.1 — вычисление коэффициентов.

```
import seaborn as sns import matplotlib.pyplot as plt

pearson_corr = df_.corr(method='pearson') spearman_corr = df_.corr(method='spearman') print("Корреляция Пирсона:\n", pearson_corr) print("\nKoppeляция Спирмена:\n", spearman_corr)

plt.figure(figsize=(8, 6)) sns.heatmap(pearson_corr, annot=True, cmap='coolwarm') plt.title("Корреляционная матрица Пирсона") plt.show()

plt.figure(figsize=(8, 6)) sns.heatmap(spearman_corr, annot=True, cmap='coolwarm') plt.title("Корреляционная матрица Спирмана") plt.title("Корреляционная матрица Спирмана") plt.show()
```

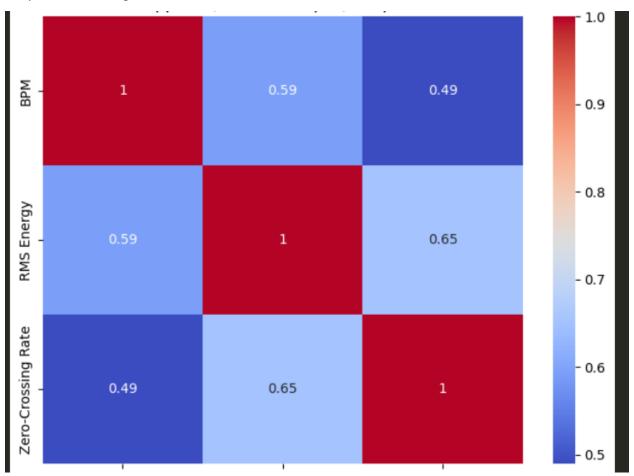
Далее рассмотрим итоговую таблицу, где показаны все значения:

Рисунок 1.2 — Таблица значений.

Корреляция Пирсона:				
	ВРМ	RMS Energy	Zero-Crossing Rate	
BPM	1.000000	0.591573	0.489428	
RMS Energy	0.591573	1.000000	0.651859	
Zero-Crossing Rate	0.489428	0.651859	1.000000	
Корреляция Спирмена:				
	ВРМ	RMS Energy	Zero-Crossing Rate	
BPM	1.000000	0.604318	0.498168	
RMS Energy	0.604318	1.000000	0.590596	
Zero-Crossing Rate	0.498168	0.590596	1.000000	

Для наглядности можно вывести карту значений, которая более понятно покажет коэффициенты:

Рисунок 1.3 — Карта значений.



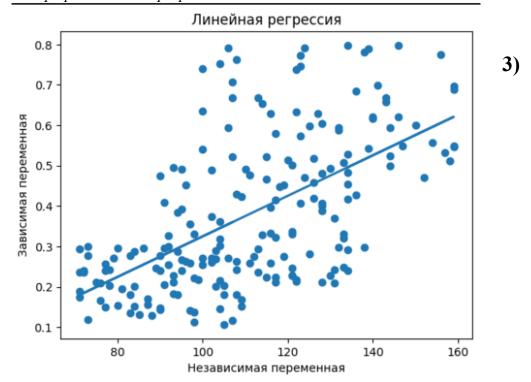
Эта карта показывает коэффициент Спирмана, и можно заметить, что она показывает то же самое, что и таблица.

Шаг 2) Линейная регрессия.

2.1) Линейная регрессия в Python.

Рисунок 2.1 — Код линейной регрессии и ее визуализации.

```
import statsmodels.api as sm
X = df_['BPM'] # Независимая переменная (Series)
Y = df_['RMS Energy'] # Зависимая переменная (Series)
   X = sm.add_constant(X) # Добавляем константу
   model = \underline{sm.OLS}(Y, X).fit() # Строим модель
   print(model.summary()) # Сводная статистика
   plt.scatter(df_['BPM'], df_['RMS Energy'])
   plt.plot(df_['BPM'], model.predict(X), linewidth=2)
   plt.title("Линейная регрессия")
   <u>plt</u> xlabel("Независимая переменная")
<u>plt</u> ylabel("Зависимая переменная")
   plt.show()
                              OLS Regression Results
Dep. Variable:
                           RMS Energy R-squared:
                                                                               0.350
Model:
                                   OLS Adj. R-squared:
                                                                              0.347
                   Least Squares F-statistic:
Method:
                                                                               106.6
                     Thu, 17 Apr 2025 Prob (F-statistic):
22:36:43 Log-Likelihood:
Date:
                                                                            2.87e-20
                                    200 AIC:
No. Observations:
                                                                              -185.1
                                     198 BIC:
Df Residuals:
                                                                               -178.5
Df Model:
Covariance Type:
                            nonrobust
                 coef std err
                                                     P>|t|
                                                                 [0.025
                                                                               0.975]
                         0.055 -3.210
0.000 10.325
const
              -0.1767
                                                     0.002
                                                                 -0.285
                                                                               -0.068
                0.0050
                                                     0.000
                                                                  0.004
                                                                               0.006
Omnibus:
                                 12.443 Durbin-Watson:
                                                                               1.858
                                  0.002 Jarque-Bera (JB):
Prob(Omnibus):
                                                                               13.301
                                  0.630 Prob(JB):
Skew:
                                                                              0.00129
Kurtosis:
                                  3.098 Cond. No.
                                                                                 582.
```



Вычисление коэффициентов в R.

Рисунок 3.1 — Вычисление коэффициентов и построение матрицы.

```
library(readr)

df <- read.csv("D:/Documents/Learning/3/R/5/df_without_genre.csv")

# Установите библиотеку ggcorrplot, если она еще не установлена

# install.packages("ggcorrplot")

# Вычисление корреляций

pearson_corr <- cor(df, method = "pearson")

spearman_corr <- cor(df, method = "spearman")

# Вывод результатов

cat("Корреляция Пирсона:\n")

print(pearson_corr)

cat("\nКорреляция Спирмена:\n")

print(spearman_corr)

# Визуализация корреляции Пирсона

library(ggcorrplot)

ggcorrplot(pearson_corr, lab = TRUE, title = "Корреляционная матрица Пирсона")
```

Рисунок 3.2 — Корреляция Пирсона и корреляция Спирмана.

```
Корреляция Пирсона:
                        BPM RMS.Energy Zero.Crossing.Rate
BPM
                  1.0000000 0.5915732
                                               0.4894280
RMS.Energy
                  0.5915732 1.0000000
                                               0.6518594
Zero.Crossing.Rate 0.4894280 0.6518594
                                               1.0000000
Корреляция Спирмена:
                        BPM RMS.Energy Zero.Crossing.Rate
BPM
                  1.0000000 0.6043181
                                               0.4981683
RMS.Energy
                  0.6043181 1.0000000
                                               0.5905963
Zero.Crossing.Rate 0.4981683 0.5905963
                                               1.0000000
```

Таблица в R идентична таблице в Python.

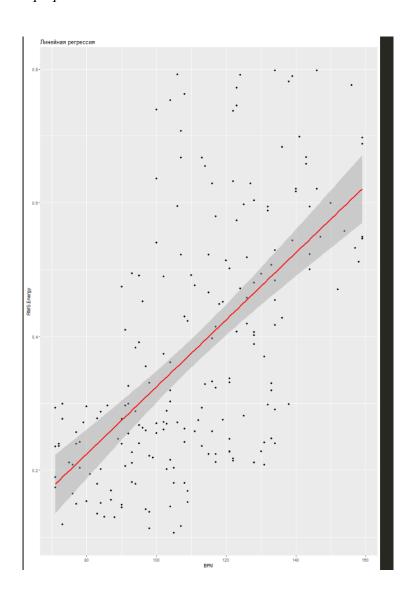
Далее реализуем линейную зависимость на языке R.

Рисунок 3.3 — Линейная зависимость в R.

```
model <- lm(BPM ~ RMS.Energy, data = df)
print(summary(model))
library(ggplot2)
print(ggplot(df, aes(x = BPM, y = RMS.Energy)) +
    geom_point() +
    geom_smooth(method = "lm", color = "□red") +
    labs(title = "Линейная регрессия"))
```

И посмотрим на получившийся график линейной зависимости.

Рисунок 3.4 — График линейной зависимости в R.



3) Сравнения результатов

И там, и там результаты получились одинаковые.

Если же рассматривать линейную зависимость, то видно, даже по графику, что они совпали.

4) Выводы

В 5 практической работе были получены результаты корреляций Спирмана и Пирсона, а также построена линейная модель регресии от двух переменных.